

【统计理论与方法】

基于模型平均的右删失数据下 加速失效时间模型的统计推断研究

王淑影, 张亚男, 程云飞

(长春工业大学 数学与统计学院, 吉林 长春 130012)

摘要:在生物统计研究领域,经常会由于各种原因出现数据删失的情况。此时研究人员不能精确观测到某个个体的确切失效时间,只能观测到生存时间大于删失时间,即右删失数据。相对于比例风险模型和可加风险模型,由于加速失效时间(AFT)模型更具有解释性,因此考虑采用 AFT 模型来对右删失数据进行建模。传统的 AFT 模型都是在协变量给定的情况下进行统计推断研究,这样可能会导致估计结果不准确。克服这种问题的有效途径是使用模型平均方法,通过对候选模型的估计量进行加权,可以减少估计的均方误差,稳健性更强。据此,从避免指定协变量构建模型引起的不准确性入手,针对右删失数据提出一种基于模型平均方法的加速失效时间模型。在极大似然估计方法的框架下,采用基于信息准则的模型平均方法进行参数估计及预测研究。数值模拟结果显示,在右删失数据下基于模型平均方法的 AFT 模型估计精度高于模型选择方法下的参数估计精度,证实了在右删失数据下使用模型平均方法可以得到更准确更稳健的估计结果。实例部分采用一组肺癌数据进行分析,结果显示基于模型平均方法的加速失效时间模型预测精度更高,进一步说明了模型平均方法的优势。

关键词:模型平均;右删失数据;加速失效时间模型;极大似然估计

中图分类号:O212 **文献标志码:**A **文章编号:**1007-3116(2022)12-0003-07

引用格式:王淑影,张亚男,程云飞.基于模型平均的右删失数据下加速失效时间模型的统计推断研究[J].统计与信息论坛,2022,37(12):3-9.

Citation Form:WANG S Y,ZHANG Y N,CHENG Y F. Statistical inference for the accelerated failure time model with right-censored data based on model averaging [J]. Journal of statistics and information,2022,37(12):3-9.

一、引言

在经济学、生物医学、临床试验等研究领域,由于各种原因经常会出现数据删失的情况。例如,在临床试验过程中,由于患者的异质性或者费用的限制等原因导致在试验结束时,某些个体还是没有发生感兴趣的事件。此时研究人员不能精确观测到某个个体的确切失效(死亡)时间,只能观测到生存时间大于删失时间,即右删失数据。针对右删失数据构建模型,最常用的就是比例风险(Proportional Hazards,PH)模型和加速失效时间(Accelerated Failure Time,AFT)模型。两者的不同之处在于 PH 模型假设对数危险率函数与协变量之间存在线性关系,而 AFT 模型直接对生存时间构建模型,研究协变量与对数生存时间的线性关系。但是,在不同实际问题中,PH 模型的比例风险假设可能很难验证,因此本文直接考虑更具有解释性的 AFT

收稿日期:2021-03-21

基金项目:国家自然科学基金青年项目“带有相依观测过程的混合型区间删失数据的统计推断研究”(11901054);中国博士后科学基金面上项目“基于时变模型的相依混合区间删失数据的统计推断及应用”(2021M700536);吉林省博士后择优资助项目

作者简介:王淑影,女,吉林榆树人,博士,副教授,博士生导师,研究方向:生物统计,经验似然,模型平均;
张亚男(通讯作者),女,陕西渭南人,硕士生,研究方向:生物统计;
程云飞,男,山东东营人,硕士生,研究方向:生物统计。

模型来对右删失数据进行建模。

在传统的 AFT 模型构建过程中,往往都是在假设协变量给定的情况下进行统计推断研究,忽略了此过程中的不确定性,导致估计量的方差被低估,进而得到不准确的预测结果。在这种情况下,有必要将传统的 AFT 模型与模型平均方法结合起来,避免忽略模型选择过程引入的不确定性。因此,本文考虑在右删失数据下,构建基于信息准则的 AFT 模型平均方法,并且基于估计和预测结合的双重视角来分析模型平均后 AFT 模型的拟合效果,以此来避免选择单一模型潜在的风险,减少估计的均方误差,提高覆盖概率,为以后更好地对 AFT 模型进行研究提供新的思路。

二、文献述评

加速失效时间(AFT)模型最早是由 Pieruschka 在 1961 年提出的,后来国内外专家学者对加速失效时间模型进行了大量的研究^[1]。例如 Buckley 等将加速失效时间模型应用到了右删失数据下,并提出了经典的 Buckley-James 估计方法^[2]。Tian 等在现状和区间删失数据下,对加速失效时间模型提出了通过 Wald-type 来构造的一种新的参数估计方法^[3]。Arnošt 等针对任意删失数据,提出了一种半参数方法来对加速失效时间模型进行估计^[4]。Li 等考虑在带治愈组的右删失数据下,提出了一种半参数加速失效时间治愈模型,并针对该模型开发了一种 EM 算法^[5]。Scolas 等针对带治愈组的区间删失数据,提出了一个十分灵活的扩展广义 Gamma 加速失效时间模型^[6]。现有文献大多考虑具有固定协变量的加速失效时间模型,但是这样做可能会丢失候选模型中包含的一些有用信息。克服这种问题的有效途径就是使用模型平均方法,通过对候选模型的估计量进行加权,可以有效地减少有用信息的遗失。

模型平均方法分为贝叶斯模型平均(Bayesian Model Averaging, BMA)和频率模型平均(Frequentist Model Averaging, FMA)两大类。许多早期工作从贝叶斯的角度讨论了模型平均方法,比如高磊等对 BMA 方法在一些难点问题上的理论进展进行了综述,并介绍了 BMA 方法在大数据背景下的应用前景^[7]。Draper 采用 BMA 方法进行预测研究并通过油价预测等两个实例证明了该方法的有效性^[8]。但是,考虑到 BMA 方法存在模型假设十分复杂且难以直观解释的问题, FMA 方法开始受到越来越多的关注和研究。例如, Zhang 等提出了一个基于函数线性回归模型的交叉验证模型平均估计方法来预测响应变量^[9]。Bai 等针对期望回归模型进行了最优模型平均估计,并证明了所得模型平均估计量是渐近最优的^[10]。Zhang 等在固定参数设置的条件下,研究了 Mallows 模型平均估计和 Jackknife 模型平均估计下模型权重的渐近性质等^[11]。这些工作为频率模型平均研究提供了深刻的理论支持和有效的方法。

文献梳理表明,国内外关于模型平均方法的研究主要聚焦于完整数据类型,对复杂删失数据的研究不多,且很少有文章研究加速失效时间模型的模型平均问题。因此无论在候选模型集合构建以及如何评价最终模型的好坏等方面都有待进一步深入研究。

三、数据、模型及似然函数

若试验过程中某个个体的确切失效(死亡)时间不能被精确观测,只能观测到生存时间大于删失时间,这种情况称为右删失数据。试验中有 n 个个体,对第 i 个个体,记感兴趣的失效时间为 T_i^* ,删失时间为 C_i ,能够得到的观测数据为 (T_i, δ_i) ,其中 $T_i = \min(T_i^*, C_i)$, $\delta_i = I(T_i^* \leq C_i)$, $i = 1, 2, \dots, n$, $I(\cdot)$ 是示性函数。当协变量给定的情况下,假设失效时间与删失时间是相互独立的,则右删失数据下的似然函数为:

$$L = \prod_{i=1}^n f(T_i)^{\delta_i} S(T_i)^{1-\delta_i}$$

考虑感兴趣事件的发生时间 T_i^* 来自于 AFT 模型:

$$\log(T_i^*) = \mu + x_i^T \beta + z_i^T \gamma + \sigma \epsilon_i$$

其中, β 和 γ 是回归系数, x_i 是 p 维协变量, z_i 是 q 维协变量, σ 是尺度参数, ϵ_i 是服从标准正态分布的误差项, μ 是截距项。 T_i^* 的生存函数为:

$$S(t_i) = P(T_i^* > t_i) = P(\log T_i^* > \log t_i) = P(\mu + x_i^T \beta + z_i^T \gamma + \sigma \epsilon_i > \log t_i) = P\left(\epsilon_i > \frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)$$

$$=S_e\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right) = 1 - \Phi\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)$$

分布函数为:

$$F(t_i) = 1 - S(t_i) = 1 - \left[1 - \Phi\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)\right] = \Phi\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)$$

密度函数为:

$$f(t_i) = F'(t_i) = \left(\Phi\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)\right)' = \frac{1}{t_i \sigma} \varphi\left(\frac{\log t_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right)$$

则对数似然函数为:

$$\begin{aligned} \log L(\theta) &= \sum_{i=1}^n \delta_i \log f(T_i) + \sum_{i=1}^n (1 - \delta_i) \log S(T_i) \\ &= \sum_{i=1}^n \delta_i \log \left(\frac{1}{T_i \sigma} \varphi\left(\frac{\log T_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right) \right) + \sum_{i=1}^n (1 - \delta_i) \log \left(1 - \Phi\left(\frac{\log T_i - \mu - x_i^T \beta - z_i^T \gamma}{\sigma}\right) \right) \end{aligned}$$

其中,未知参数为 $\theta = (\beta^T, \gamma^T, \mu, \sigma)^T$ 。下面从模型平均角度,给出 AFT 模型中感兴趣参数的估计方法及预测方法。

四、基于信息准则的 AFT 模型平均方法

在生物统计领域中,已有研究大多是先选定一个模型,然后对选定模型进行统计推断,这样可能会造成估计结果不稳健。而模型平均是解决这个问题的有效方法,模型平均方法通过考虑模型的不确定性和优化模型权重来最小化误差。

在本文中,我们考虑 $p+q$ 个协变量,其中 x_i 中包括 p 个确定被包含在模型中的协变量, z_i 中包括 q 个可能被包含在模型中的协变量,那么就会产生 2^q 个候选模型。对第 m 个候选模型,假设为如下 AFT 模型:

$$\log(T_i^*)_m = \mu_m + x_{im}^T \beta_m + z_{im}^T \gamma_m + \sigma_m \epsilon_{im}$$

其中, $m=1,2,\dots,2^q$ 代表模型的个数, $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$ 代表 p 个确定被包含在模型中的协变量, $z_i = (z_{i1}, z_{i2}, \dots, z_{iq})^T$ 代表 q 个可能被包含在模型中的协变量, σ_m 是尺度参数, ϵ_{im} 是服从标准正态分布的误差项, μ_m 是截距项。未知参数为 $\theta_m = (\beta_m^T, \gamma_m^T, \mu_m, \sigma_m)^T$,对应的未知参数估计则记为 $\hat{\theta}_m = (\hat{\beta}_m^T, \hat{\gamma}_m^T, \hat{\mu}_m, \hat{\sigma}_m)^T$ 。

均方根误差是一个能够较好地衡量估计精度的评价量,一般来说均方根误差值越小则估计精度越高^[12]。

$$\theta_m^{\text{rmse}} = (E(\hat{\theta}_m - \theta_m)^2)^{1/2}$$

在实际情况中,受试者可能更关心的指标是生存概率,也就是在单位时间内生存的可能性大小。

$$Su_m = 1 - \Phi\left(\frac{\log t_m - \mu_m - x_m^T \beta_m - z_m^T \gamma_m}{\sigma_m}\right)$$

对应累积生存率为 0.5 时的生存时间叫做中位生存时间。这是一个非常重要的指标,有时比平均生存时间重要^[13]。

$$\hat{\xi}_m(r) = \exp(\sigma_m \Phi(r)^{-1} + \mu_m + x_m^T \beta_m + z_m^T \gamma_m), 0 < r < 1$$

其中, r 为 T 分布的 50% 分位点。

如果给定了一组数据,但是产生数据的真实模型未知时,需要找到所有可能的模型,这时就要通过比较研究哪个模型的拟合效果较好来决定,这个过程就是模型选择。在模型选择中,最常用的是基于 Akaike 信息准则(AIC)的模型选择和基于 Bayesian 信息准则(BIC)的模型选择,表达式分别如下所示:

$$AIC_m = -2\log \ell_m + 2l_m, BIC_m = -2\log \ell_m + l_m \log n$$

其中, ℓ_m 表示模型 m 的极大似然函数, l_m 表示模型 m 中未知参数的个数。根据 AIC_m 值和 BIC_m 值分别对所有模型进行排序,最大的 AIC_m 值和 BIC_m 值所对应的模型即为最优模型^[12,14]。

通过模型选择可能得到存在有局部误差的模型,进而导致估计结果不准确,这时模型平均方法就会被考虑。模型平均方法最核心的问题就在于权重的选择,本文采用基于 Smoothed AIC(S-AIC)和 Smoothed BIC(S-BIC)的模型平均方法来计算组合权重,权重的表达式如下:

$$\omega_m = \frac{\exp(-xIC_m/2)}{\sum_m \exp(-xIC_m/2)}$$

其中, m 代表第 m 个模型, ω_m 是各个候选模型的权重, xIC 表示 AIC 或 BIC。设 $\omega = (\omega_1, \omega_2, \dots, \omega_m)^T$ 是 m 个模型的权重向量, 则:

$$\nu = \{\omega \in [0, 1]^m : 0 \leq \omega_m \leq 1, \sum_{m=1}^{2^q} \omega_m = 1\}$$

对每个候选模型进行极大似然估计后会得到各个参数对应的估计值, 则模型平均后的未知参数估计的表达形式如下:

$$\hat{\theta}_{MA} = \sum_{m=1}^{2^q} \omega_m \hat{\theta}_m$$

模型平均后的生存概率的具体形式如下:

$$Su_{MA} = \sum_{m=1}^{2^q} \omega_m \left[1 - \Phi \left(\frac{\log t_m - \mu_m - x_m^T \beta_m - z_m^T \gamma_m}{\sigma_m} \right) \right]$$

模型平均后的中位生存时间表达形式如下:

$$\hat{\xi}_{MA}(r) = \sum_{m=1}^{2^q} \omega_m (\exp(\sigma_m \Phi(r)^{-1} + \mu_m + x_m^T \beta_m + z_m^T \gamma_m)), 0 < r < 1$$

其中, r 为 T 分布的 50% 分位点。

五、模拟研究

本文将通过极大似然估计方法来验证所提方法的有效性。数据 T_i^* 由以下模型生成:

$$\log(T_i^*) = \mu + x_{i1}\beta_1 + x_{i2}\beta_2 + z_{i1}\gamma_1 + z_{i2}\gamma_2 + z_{i3}\gamma_3 + z_{i4}\gamma_4 + \sigma\epsilon_i$$

其中, $i=1, 2, \dots, n$, $\beta_1, \beta_2, \gamma_1, \gamma_2, \gamma_3, \gamma_4$ 是回归系数, σ 是尺度参数, ϵ_i 是服从标准正态分布的误差项, μ 是截距项。 x_{i1}, x_{i2} 是确定包含在模型中的协变量, $z_{i1}, z_{i2}, z_{i3}, z_{i4}$ 是可能包含在模型中的协变量, 那么候选模型为 $2^4=16$ 个。各个协变量由以下分布生成: $x_{i1} \sim N(0, 1), x_{i2} \sim N(0, 1), z_{i1} \sim N(0.5, 1), z_{i2} \sim U(0, 1), z_{i3} \sim P(1), z_{i4} \sim B(1, 0.5)$ 。 C 服从均匀分布 $U(0, cl)$, 其中 cl 控制删失率。本文考虑两组参数真值, 设置 A 为窄模型(即只包含确定协变量的模型): $\beta_1=1, \beta_2=1, \gamma_1=0, \gamma_2=0, \gamma_3=0, \gamma_4=0, \mu=0.5, \sigma=0.4$; 设置 B 为宽模型(即包含确定协变量和所有可能协变量的模型): $\beta_1=-0.2, \beta_2=0.2, \gamma_1=0.2, \gamma_2=-0.3, \gamma_3=0.2, \gamma_4=-0.2, \mu=0.5, \sigma=0.4$ 。删失比例为 30%, 模拟循环 1 000 次。

在模拟研究中, 分别计算出 16 个候选模型中未知参数、生存概率、中位生存时间三项的均方误差值以及 AIC、BIC 的值, 并通过 S-AIC、S-BIC 计算各个候选模型的权重。然后计算四种方法下的均方根误差, $\left\{ (1000)^{-1} \sum_{j=1}^{1000} (\hat{\theta}_j - \theta_{true})^2 \right\}^{1/2}$ 。这里我们感兴趣的指标有 3 个^[12]: (a) 待估参数均方根误差值的模; (b) $t=1, x=0.2, z=0.2$ 时生存概率的均方根误差; (c) $r=0.5, x=0.2, z=0.2$ 时中位生存时间的均方根误差。下面给出了设置 A 和设置 B 分别在样本量为 100 和 200 时, (a)、(b)、(c) 三个指标的结果, 见表 1 和表 2。

表 1 设置 A 两组样本量下三个感兴趣指标的均方根误差

样本量	指标	S-AIC	AIC	S-BIC	BIC
$n=100$	(a)	0.121 2	0.242 2	0.104 0	0.240 4
	(b)	0.007 0	0.009 1	0.006 8	0.009 1
	(c)	0.156 3	0.222 3	0.149 1	0.220 2
$n=200$	(a)	0.084 9	0.171 9	0.071 2	0.172 1
	(b)	0.005 0	0.006 4	0.004 8	0.006 5
	(c)	0.108 8	0.155 5	0.103 2	0.154 2

表 2 设置 B 两组样本量下三个感兴趣指标的均方根误差

样本量	指标	S-AIC	AIC	S-BIC	BIC
$n=100$	(a)	0.207 1	0.269 1	0.177 7	0.281 4
	(b)	0.043 9	0.058 0	0.042 4	0.058 8
	(c)	0.176 3	0.179 6	0.147 7	0.177 5
$n=200$	(a)	0.167 1	0.194 3	0.145 3	0.202 3
	(b)	0.038 9	0.050 0	0.038 7	0.049 1
	(c)	0.133 6	0.150 4	0.112 0	0.149 7

在表 1 和表 2 中, AIC 代表基于 AIC 准则的模型选择方法, BIC 代表基于 BIC 的模型选择方法, S-AIC 代表基于 Smoothed AIC 准则的模型平均方法, S-BIC 代表基于 Smoothed BIC 准则的模型平均方法(下

同)。在设置 A 中,窄模型是真实模型。从理论上来说,BIC 是一个一致的模型选择器,通常适用于具有少量参数的模型,因此在真实模型为窄模型的情况下,BIC 优于 AIC,S-BIC 优于 S-AIC。在指标(a)和指标(c)下,基于模型平均方法得到的结果与基于模型选择方法得到的结果相差较大,基于信息准则的 AFT 模型平均方法在参数数量较少时的估计精度更高。对于设置 B,如果真实模型中的非零参数较多,S-BIC 还是最好的方法。这可能是因为 AIC 假设真实模型是高维的,需要在有限的情况下尽可能多的参数来描述它。Sakamoto 等指出,AIC 不是估计真实模型的标准,而是最佳模型拟合的标准^[15]。也就是说,AIC 力求找到最佳的近似模型,如果数据较少模型的维数将会降低,随着可用信息的增多,模型的维数将会增加。相比之下,BIC 是一致的。它假设真实模型存在且是低维的,可对真实模型进行一致性估计。

总的来说,无论真实模型为窄模型还是宽模型,基于 Smoothed BIC 准则的 AFT 模型平均方法的表现都是最好的。这主要是因为模型选择方法在使用过程中是将最终选择的模型视为提前选择,忽略了模型选择过程带来的额外不确定性,进而导致了较大的估计误差。随着样本量大小的增加,在局部错误指定的假设下,参数将会更接近真实值,所有候选模型都更接近真实模型,因此模型平均方法和模型选择方法的估计精度都在逐渐提高。

六、肺癌数据分析

使用本文提出的模型平均方法对一组肺癌数据进行研究,以此来进一步证明所提出方法的有效性。这组完整的数据集来自于 R 软件包 survival 中,是为比较接受两种不同治疗方案的肺癌患者生存时间而设计的一个临床试验。在这项研究中,137 名肺癌患者被随机分为两组,分别接受两种不同的治疗方案,感兴趣的是肺癌患者的生存时间。数据集中有 6 个协变量,包括治疗方案(x_1)、细胞类型(x_2)、卡诺斯基评分(z_1)、从诊断到治疗的时间(z_2)、年龄(z_3)以及是否有过既往治疗(z_4)。我们感兴趣的问题是基于一组 6 个协变量,对数据进行预测。Kalbfleisch 等人的研究结果表明,不同的治疗方案和细胞类型会对肺癌患者的生存时间产生显著影响^[16]。所以,选定治疗方案和细胞类型为必选协变量,其他 4 个协变量则为候选协变量,这样共有 $2^4=16$ 个不同的候选模型。

为了比较 AIC、BIC、S-AIC 和 S-BIC 四种方法的效果,随机地将数据分为两部分,分别记为训练集 $D_{(0)}$ 和测试集 $D_{(1)}$ ^[17]。训练集的样本量 n_0 依次选取了 80,90,100,110 和 120,而测试集的样本量大小为 $n-n_0$,其中 $n=137$ 是整体的样本量。首先对 n_0 个样本进行极大似然估计,其次对 $n-n_0$ 个样本进行预测,并计算样本的均方预测误差(Mean Squared Prediction Error,MSPE),即:

$$MSPE^{(d)} = \frac{1}{n-n_0} \sum_{i=n_0+1}^n (T_i^{(d)} - \hat{\rho}_i^{(d)})^2$$

其中, $d=1,2,\dots,1\ 000$ 代表循环次数。 $T_i^{(d)}$ 是第 i 个个体的生存时间在第 d 次循环中的真实值, $\hat{\rho}_i^{(d)}$ 是第 i 个个体在第 d 次循环中的预测值。MSPE 值越小代表预测精度越高。四种方法下 MSPE 的均值和中位数结果见表 3。

从表 3 中 MSPE 的均值和中位数的角度来看,最优的方法是 S-AIC,它比其他三种方法的 MSPE 的均值和中位数都要小。S-AIC 和 S-BIC 方法的 MSPE 的均值和中位数都比相应的 AIC 和 BIC 方法要小,这说明基于模型平均方法的 AFT 模型预测结果比模型选择的预测结果更准确。此外 S-AIC 方法略优于 S-BIC 方法,AIC 方法略优于 BIC 方法。尽管

表 3 肺癌患者生存时间的 MSPE

n_0	指标	S-AIC	S-BIC	AIC	BIC
80	均值	3.183 8	3.428 8	6.302 6	6.529 1
	中位数	3.115 1	3.277 7	5.870 7	5.935 9
90	均值	3.151 4	3.391 0	6.227 0	6.403 4
	中位数	3.167 2	3.398 9	5.889 4	5.945 5
100	均值	3.128 6	3.379 1	6.139 2	6.365 1
	中位数	2.916 9	3.150 4	5.772 4	5.865 1
110	均值	3.114 6	3.343 9	6.070 9	6.239 6
	中位数	2.489 7	2.875 2	5.813 9	5.876 2
120	均值	2.866 7	3.317 8	6.069 9	6.171 2
	中位数	2.146 0	2.631 8	5.666 9	5.729 6

表 3 中四个方法的 MSPE 的均值和中位数有较大的不同,但是可以清楚地分辨出各个方法的表现。为了检验所提方法得出的结论,进一步考虑了 Diebold-Mariano 检验,通过 R 软件包 forecast 中的 dm.test 函数计算出两种方法构造的模型之间的 DM 统计量和 p 值,以此来观察两种模型预测能力的优劣性^[18]。DM 检验

的原假设为 H_0 :DM 统计量均值为 0,即两种方法构造的模型预测能力相同;备择假设为 H_1 :DM 统计量的均值不为 0,也就是说两种方法构造的模型具有不同的预测能力。正的 DM 值表明分母对应的方法优于分子对应的方法,若 DM 检验的 p 值小于 0.05,拒绝原假设,那么就说明两种方法构造的模型具备不同的预测能力。

表 4 肺癌患者生存时间 MSPE 的 DM 统计量

n_0	指标	$\frac{S-AIC}{S-BIC}$	$\frac{S-AIC}{BIC}$	$\frac{S-AIC}{AIC}$	$\frac{AIC}{S-BIC}$	$\frac{AIC}{BIC}$	$\frac{BIC}{S-BIC}$
80	DM	-23.532	-78.678	-75.119	75.050	-34.212	78.653
	p 值	0.00	0.00	0.00	0.00	0.00	0.00
90	DM	-25.113	-145.340	-168.860	187.720	-23.528	141.610
	p 值	0.00	0.00	0.00	0.00	0.00	0.00
100	DM	-52.620	-140.630	-134.080	131.700	-20.727	138.480
	p 值	0.00	0.00	0.00	0.00	0.00	0.00
110	DM	-51.993	-117.240	-114.890	110.620	-16.379	113.160
	p 值	0.00	0.00	0.00	0.00	0.00	0.00
120	DM	-79.931	-94.631	-93.298	87.090	-13.588	88.528
	p 值	0.00	0.00	0.00	0.00	0.00	0.00

在表 4 的前 3 列中,我们可以看到 DM 的值都是负的,且 p 值几乎为 0,这表明 S-AIC 方法显著优于其他三种方法。第 4 列和第 6 列中的 DM 值都是正的,且 p 值几乎为 0,说明 S-BIC 方法显著优于 AIC 和 BIC 方法。第 5 列中的 DM 值都是负的,且 p 值几乎为 0,说明 AIC 方法优于 BIC 方法。这些结论与表 3 中的结论是一致的。

七、总结及讨论

本文主要考虑右删失数据下,提出基于 AFT 模型的频率模型平均方法,使用极大似然方法进行参数估计及预测,其中误差项服从标准正态分布。模拟研究表明,所提方法的表现更好。模型平均方法考虑了所有协变量对响应变量的影响,而模型选择是只用选择出来的部分协变量来解释响应变量。由于模型平均方法是根据协变量的个数来构建候选模型,所以当协变量比较多时,具体实现计算就会变得十分复杂^[19]。近些年来频率模型平均方法快速发展,提出了各种最优模型平均的方法,但本文仅考虑了基于信息准则的模型平均方法。如果使用渐近最优的模型平均方法,如 Mallows 模型平均方法、Jackknife 模型平均方法、OPT 模型平均方法等,也许会得到更好的估计结果。这些问题值得我们进一步研究。

参考文献:

- [1] PIERUSCHKA E. Relation between lifetime distribution and the stress level causing the failures[S]. Sunnyvale;lockheed missile and space division,1961:1-30.
- [2] BUCKLEY J,JAMES I. Linear regression with censored data[J]. Biometrika,1979,66(3):429-436.
- [3] TIAN L,CAI T. On the accelerated failure time model for current status and interval censored data[J]. Biometrika,2006,93(2):329-342.
- [4] ARNOŠT K,EMMANUEL L,JOAN F. Accelerated failure time model for arbitrarily censored data with smoothed error distribution[J]. Journal of computational and graphical statistics,2005,14(3):726-745.
- [5] LI C,TAYLOR M. A semi-parametric accelerated failure time cure model[J]. Statistics in medicine,2002,21(21):3235-3247.
- [6] SCOLAS S,GHOUGH A,LEGRAND C,et al. Variable selection in a flexible parametric mixture cure model with interval-censored data[J]. Statistics in medicine,2016,35(7):1210-1225.
- [7] 高磊,刘乐平,卢志义. 大数据背景下贝叶斯模型平均的理论突破与应用前景[J]. 统计与信息论坛,2016,31(6):14-22.
- [8] DRAPER D. Assessment and propagation of model uncertainty[J]. Journal of the royal statistical society,1995,57(1):45-70.

- [9] ZHANG X, CHIOU J, MA Y. Functional prediction through averaging estimated functional linear regression models[J]. *Biometrika*, 2018, 105(4): 945-962.
- [10] BAI Y, JIANG R J, ZHANG M L. Optimal model averaging estimator for expectile regressions[J]. *Journal of statistical planning and inference*, 2022, 217: 204-223.
- [11] ZHANG X, LIU C. Inference after model averaging in linear regression models[J]. *Econometric theory*, 2019, 35(4): 816-841.
- [12] NILS L, GERDA C. Focused information criteria and model averaging for the COX hazard regression model[J]. *Journal of the American statistical association*, 2006, 101(476): 1449-1464.
- [13] GOULD S. The median isn't the message[J]. *Australian veterinary practitioner*, 2005, 35(2): 66-68.
- [14] NILS L, GERDA C. Frequentist model average estimators[J]. *Journal of the American statistical association*, 2003, 98(464): 879-899.
- [15] SAKAMOTO Y, ISHIGURO M, KITAGAWA G. Akaike information criterion statistics[J]. *Technometrics*, 1986, 31(2): 270.
- [16] KALBFLEISCH J D, PRENTICE R L. The statistical analysis of failure time data[M]. Hoboken: John Wiley & Sons, 2011: 119-121.
- [17] 朱容, 邹国华, 张新雨. 部分函数线性模型的模型平均方法[J]. *系统科学与数学*, 2018, 38(7): 777-800.
- [18] DIEBOLD F, MARIANO R. Comparing predictive accuracy[J]. *Journal of business and economic statistics*, 1995, 13(3): 253-263.
- [19] 郑世刚. 基于 BMA 方法的中国房价长期影响因素研究——兼论房地产长效机制构建[J]. *统计与信息论坛*, 2020, 35(3): 102-112.

Statistical Inference for the Accelerated Failure Time Model with Right-censored Data Based on Model Averaging

WANG Shu-ying, ZHANG Ya-nan, CHENG Yun-fei

(School of Mathematics and Statistics, Changchun University of Technology, Changchun 130012, China)

Abstract: In the research fields of economics, biomedicine, clinical trials and so on, censored data often occurs for various reasons. As the popular alternative model of proportional hazards model, AFT model, which directly models the linear relationship between covariates and log survival time, is considered to model the right-censored data. In the process of traditional AFT model construction, statistical inference research is often carried out under the assumption of given covariates. Then the uncertainty property will be ignored. And to deal with the problem, the model averaging method is introduced. By weighting the estimators of the candidate models, the mean square error of the estimation can be reduced and the robustness is stronger. In the framework of maximum likelihood estimation method, the model averaging method based on information criterion is used for parameter estimation and prediction. The numerical simulation results show that the estimation accuracy of AFT model based on model averaging method is higher than that of parameter estimation under model selection method under right-censored data. In the example part, a group of lung cancer data is used for analysis. The results show that the prediction accuracy of the accelerated failure time model based on the model averaging method is higher, which further explains the advantages of the model averaging method.

Key words: model averaging; right-censored data; accelerated failure time model; maximum likelihood estimation

(责任编辑:崔国平)